Stateless In-Memory Cache — 비대칭 워크로드 환경에서의 분산 KV 스토리지 Scale-out

> 본 문서는 공개된 기술 레퍼런스와 직접 수행한 분석·실험을 토대로 작성되었으며, 회사의 기밀정보나 영업비밀을 포함하지 않습니다.

항목	내용
회사	Newmetric
언어	Go
역할	리서치·설계·구현

배경 및 문제 정의

B2B SaaS 형태로 여러 노드의 RPC 엔드포인트를 제공하는 서비스를 운영하면서, 특정 노드에 예측 불가능한 트래픽 스파이크가 발생하는 문제를 겪었습니다.

기존 구조로는 scale-out을 위해 노드를 추가하려면 최신 snapshot이 필요했기 때문에, hot standby 노드를 준비해도 갑작스러운 트래픽 spike에 즉각 대응하는 horizontal scale-out은 사실상 불가능했습니다. 최신 state snapshot은 100 GB 내외에 달하기도 하여, 유연한 scale-out을 위해 복수의 노드를 미리 준비해두는 것은 인프라 비용 측면에서도 큰 부담이었습니다.

핵심은 **RPC 서비스의 트래픽 특성**이었습니다. read 쓰루풋은 매우 높지만, write는 주기적 timestamp마다 한 번씩 batch로 발생하는 구조였습니다. write 워크로드와 read 워크로드를 완전히 분리하고, **stateless cache 레이어**를 별도로 구성하면 캐시 노드만 scale-out해서 RPC를 수행할 수 있다는 아이디어로부터 시작했습니다.

1차 시도: RwLock 기반 BTree In-Memory KV Store

google/btree를 기반으로 `sync.RWMutex`를 씌운 단순한 in-memory KV store를 먼저 구현했습니다. k6로 **프로덕션 트래픽 분포를 재현**한 stress 테스트를 수행한 결과, 두 가지 병목이 명확히 드러났습니다.

- **Write lock 동안 모든 read가 블로킹**: 주기적 write batch가 flush되는 순간 write lock을 잡으면, 그 시점에 대기 중인 read goroutine이 전부 멈추는 구간적 지연이 발생했습니다.

pprof로 측정해보면 mutex blocking이 지배적으로 나타났고, 결론적으로 **하드웨어 병렬성을 제대로 활용하지 못하는 구조**라는 판단 하에 lock-free 방향으로 전환했습니다.

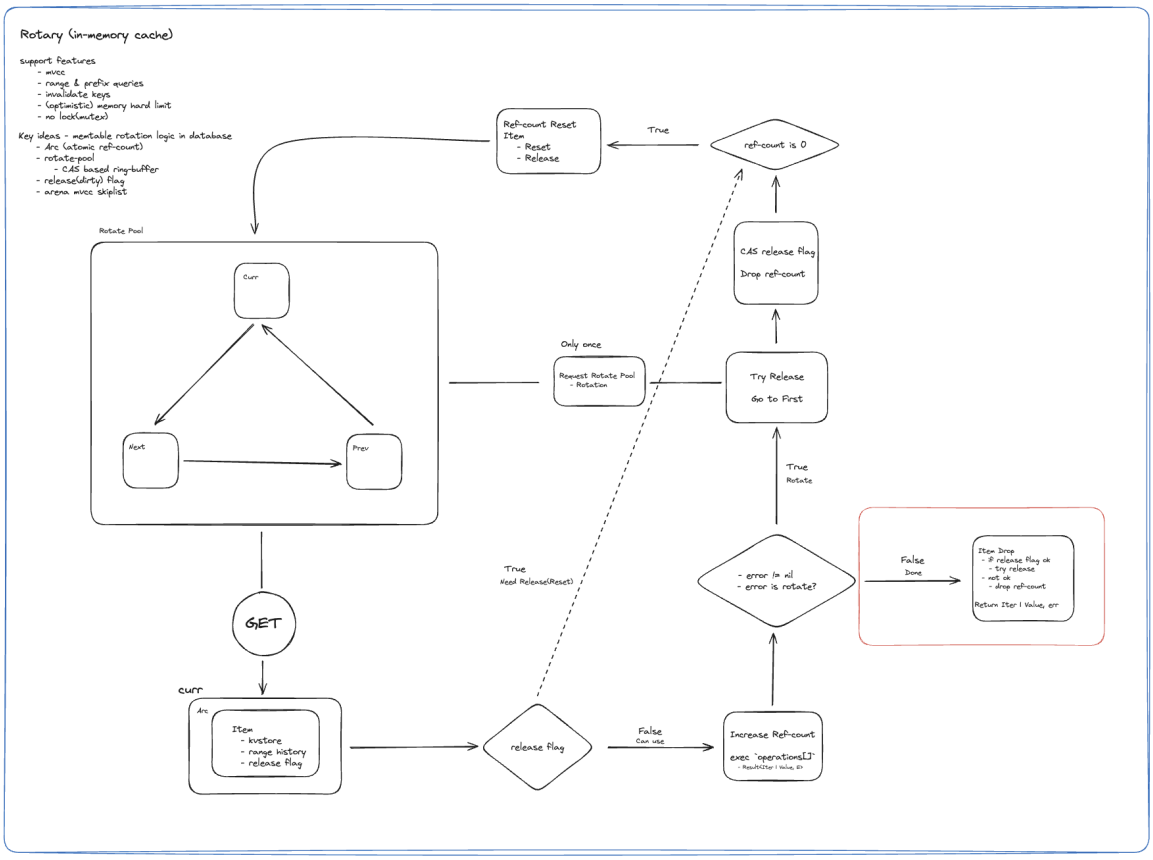

그림 1: 아키텍처 개요

2차 시도: MVCC Arena Skiplist — Lock-free In-Memory KV Cache

단조증가하는 timestamp는 MVCC(Multi-Version Concurrency Control) 방식에 자연스럽게 활용할 수 있습니다. write 시 lock을 잡는 대신 timestamp를 버전으로 삼아 버전을 나눠 읽고 쓸 수 있습니다. arena 기반 lock-free skiplist를 활용해 **iterator를 지원하는 in-memory KV cache**를 구현했습니다. arena 할당 방식은 개별 노드마다 별도의 메모리를 할당하지 않고 미리 확보한 연속 메모리 블록에서 순차 할당하므로, 최대한 GC 압박 없이 작동하도록 구현하였습니다.

Arena Full 문제: 3슬롯 Ring Buffer + Arc Reference Counting

arena 방식의 본질적인 한계는 메모리가 꽉 차면(`ArenaFull`) 더 이상 쓸 수 없다는 점입니다. 단순히 즉시 리셋하면 살아있는 iterator가 댕글링 포인터를 참조하는 문제가 생깁니다.

이를 해결하기 위해 **3슬롯 Rotary Pool**을 설계했습니다.

```
[Next] → [Current] → [Previous]
  ↑                        |
  └────────────────────────┘  (rotation)
```

- **Current**: 현재 read/write 요청을 서빙하는 멤테이블
- **Next**: 이미 리셋이 완료되어 다음 rotation 대기 중인 멤테이블
- **Previous**: rotation 직후 아직 살아있는 long-lived iterator들이 참조 중인 멤테이블

각 슬롯은 **Arc(Atomic Reference Counting)** 포인터로 감싸, ref count가 0이 되는 순간 arena를 안전하게 리셋합니다. `ArenaFull` 발생 시 CAS(Compare-And-Swap)로 슬롯을 교체하고, GC 고루틴이 ref count를 모니터링하며 안전한 시점에 리셋을 수행합니다. 이 설계를 통해 **no mutex, lock-free**로 메모리 상한을 지키면서도 iterator consistency를 보장했습니다.

메모리 상한은 설정 가능하며, arena가 가득 찰 경우 회전이 발생하고, 별도로 설정 가능한 임계값을 초과하는 요청은 캐시를 우회해 마스터 DB에서 직접 fetch하도록 구성하여 OOM 없이 메모리를 예측 가능하게 유지했습니다.

Range Query 문제: Arena Skiplist 기반 Range History

일반적인 캐시 레이어에서 단순 `Get` 요청은 hit/miss 상태를 키 단위로 관리하면 충분합니다. 하지만 **Iterator(range/prefix query)** 를 지원하려면 복잡한 문제가 생깁니다.

예를 들어 `exchange/{address}/{coin_address}` 형태의 key 스페이스를 생각해 보면, 실제 DB에는 `[1, 10, 99]`처럼 **sparse하게** 키가 존재합니다. 클라이언트가 `[1, 100)` 범위를 요청했을 때, 캐시에 `1`과 `10`이 있다고 해서 `[1, 100)` 범위 전체가 캐시에 있다고 볼 수 없습니다—`[11, 99]` 사이에 DB에서 아직 가져오지 않은 키가 있을 수 있기 때문입니다. 따라서 **"이 구간 `[start, end)`의 데이터를 마스터 DB에서 이미 가져왔다"는 메타데이터**를 별도로 추적해야 합니다.

Range History를 별도의 arenaskl 기반 skiplist로 구현했습니다. 설계 포인트는 간단합니다.

- skiplist의 **key = range end**, **value = range start**로 저장
- `Include(start, end)` 쿼리 시 `SeekGE(start)` + `Next()`으로 O(log N + K) 포함 여부 판별
- 겹치는 range(`[a,d)` + `[b,e)`)는 쿼리 시점에 `min(start), max(end)`로 merge

리서치: Copy-on-Write Interval Tree + Atomic Pointer Swap

Range History에서 read-heavy 워크로드라는 점을 고려해, range 병합을 쿼리 시점이 아닌 **삽입 시점에** 미리 수행하는 방향을 검토했습니다. 삽입 시 겹치는 범위를 병합할 수 있는 자료구조나 방법론을 찾다가 **Interval Tree**에 도달했습니다.

Interval Tree를 적용해보니 RwLock 기반으로 구현하면 처음의 BTree와 같은 contention 문제가 재발했습니다. 이를 해결하기 위해 `tidwall/btree`의 **Copy-on-Write** 구현에서 힌트를 얻었습니다. tidwall/btree는 각 노드에 `isoid uint64`(단조증가 ID)를 부여하고, write 시 노드의 `isoid`와 현재 트리의 `isoid`를 비교해 (`(*cn).isoid != tr.isoid`) 다르면 해당 노드를 복사(clone)한 뒤 수정합니다.

이를 Interval Tree에 적용하고, 두 개의 트리(`read tree`, `write tree`)를 `atomic.Pointer`로 관리하는 방식을 고안했습니다.

- **Read**: `atomic.Pointer.Load()`로 read tree를 lock 없이 참조
- **Write**: write tree에 CoW로 수정 후, 완료되면 `atomic.Pointer.CompareAndSwap()`으로 read tree와 교체

실제 구현과 벤치마크까지 진행했으나, B2B 계약 기간 만료로 프로덕션 배포 전 단계에서 프로젝트가 마무리되었습니다.

품질 관리: 릴리즈별 Regression Benchmark

중요 배포마다 k6로 stress 테스트(`vus=500`, `duration=10s`)를 실행해 이전 버전 대비 성능 회귀(regression)가 없는지 확인했습니다. 이 과정을 통해 각 최적화 단계의 실제 효과를 수치로 검증하고, 예상치 못한 성능 저하를 사전에 차단했습니다.

성과

항목	기존 (단일 노드)	Newmetric Edge 노드 (1 replica)
하드웨어	16c / 64 GiB	**2c / 2 GiB** + remote DB 1c/4g
Throughput	530 req/s	**7,531 req/s**
p95 Latency	913 ms	**95 ms**
수평 확장	사실상 불가 (snapshot 필요)	**replica 수에 비례해 선형 확장**

사용 하드웨어를 1/8 수준으로 줄이면서 처리량은 약 **14배** 향상됐습니다.

결론

단계	상태	비고
RwLock BTree KV Store	구현 완료 · 성능 한계 확인	mutex blocking이 지배적, lock-free로 방향 전환
MVCC Arena Skiplist (lock-free in-memory KV cache)	**프로덕션 배포**	timestamp를 버전으로 활용, 읽기 경합 제거
3슬롯 Ring Buffer + Arc Ref Counting	**프로덕션 배포**	arena safe rotation 달성, no-mutex, 2GB 상한
Range History (arenaskl 기반 skiplist)	**프로덕션 배포**	O(log N) range 포함 판별, prefix query 지원
CoW Interval Tree + Atomic Pointer Swap	구현·벤치마크 완료 · 미배포	재직 기간 내 프로덕션 반영 전 종료

단조증가하는 timestamp를 MVCC 버전으로 활용하면, write 시 lock 없이 다중 버전 읽기가 가능하고 arena를 안전하게 순환시킬 수 있습니다.